

Parcial — El agente evaluador

Programación de y con Agentes de IA · MBA UCEMA · 2026 2T · Prof. Alfredo B. Roisenzvit

Grupal (hasta 6 integrantes) · Abre: jueves 27/8, 22:00 · Cierra: jueves 10/9, 18:59 — antes de la última clase · Prueba de fuego: en vivo, esa misma noche

Qué es

El parcial de la materia es construir un **agente evaluador**: un sistema capaz de corregir los trabajos finales de la cursada. En la última clase, todos los evaluadores pasan por una prueba de fuego en vivo — y el mejor es elegido **el agente evaluador de la materia**: el único que corrige los trabajos finales de todos.

La lógica la vieron en clase: la rúbrica con la que se corrigen sus entregas es un prompt — una especificación ejecutable. Ahora la escriben ustedes. Evaluar bien es definir «bien hecho» con tanta precisión que hasta una máquina puede aplicarlo; el parcial es demostrar esa competencia.

Las cuatro piezas que entrega cada grupo

1 · La rúbrica ejecutable. La rúbrica oficial del trabajo final (publicada en el documento del final) define *qué* dimensiones se evalúan y sus pesos. El trabajo de ustedes es volverla **ejecutable**: escalas por nivel, qué evidencia exige cada puntaje, ejemplos de qué merece un nivel alto y uno bajo en cada dimensión. Tan precisa que un agente la aplica igual dos veces; tan legible que un humano puede discutirla.

2 · El agente corrector. El system prompt (más las herramientas que necesite) que recibe un trabajo final real — un repositorio — y devuelve: puntaje por dimensión, justificación breve de cada puntaje citando evidencia del trabajo, y una sugerencia concreta de mejora. Salida en formato estructurado, idéntico en cada corrida.

3 · Tres casos de prueba. Tres trabajos de ejemplo contruidos por ustedes: uno **excelente**, uno **flojo**, y uno **tramposo** — que intenta engañar al corrector (afirma cosas que no hizo, infla su documentación, apela a la simpatía del evaluador). Su agente tiene que puntuar alto al primero, bajo al segundo, y **detectar al tercero**.

4 · La calibración. La evidencia de que las notas del agente coinciden con el criterio humano del grupo sobre esos mismos casos: qué notas puso el agente, qué notas hubieran puesto ustedes, dónde no coincidían, qué ajustaron en la rúbrica o en el corrector, y cómo quedó después del ajuste.

Estructura obligatoria del repositorio

Un repositorio público de GitHub por grupo, con esta estructura (la corrección la asiste un agente: el formato importa):

README.md	– el README estándar de la materia + integrantes del grupo
rubrica.md	– la rúbrica ejecutable
agente/	– system prompt y configuración del corrector
casos/excelente/	– caso de prueba 1
casos/flojo/	– caso de prueba 2
casos/tramposo/	– caso de prueba 3
calibracion.md	– la evidencia de calibración

La **historia de commits** debe mostrar el trabajo real del grupo: quién aportó qué, cómo evolucionó la rúbrica. Un repo con un único commit del último día cuenta una historia — y no es buena.

Cómo se evalúa el parcial

Criterio	Peso
Rúbrica ejecutable: precisión, escalas, evidencia exigida por nivel	25
Agente corrector funcionando: corre sobre un repo real y devuelve el formato completo	25
Casos de prueba: los tres existen y el corrector los distingue (incluido el tramposo)	20
Calibración documentada: desacuerdos encontrados, ajustes hechos, resultado	15
Proceso grupal: historia de commits, iteraciones de la rúbrica, decisiones registradas	15

La prueba de fuego es pública y tiene premio: en la última clase, cada agente evaluador corrige en vivo casos que nunca vio — y de esa prueba se elige **el agente evaluador de la materia**: uno solo, el que va a corregir todos los trabajos finales tras el cierre del domingo 13/9. Un evaluador que se desploma frente a un caso real dice algo sobre su construcción, y la clase entera lo va a ver. Construyan para ganar ese lugar.

Reglas de la casa, aplicadas

Nadie del grupo escribe código: se construye describiendo, iterando y documentando, con la IA como tutor. Si el corrector «no puede» leer un repo, la pregunta es qué herramienta o instrucción le falta. Y el proceso documentado vale: un desacuerdo de calibración honesto y bien resuelto suma más que una calibración perfecta sin historia.

Entrega

Un integrante sube el **link al repositorio del grupo** en la actividad *Parcial* del campus, antes del **jueves 10 de septiembre, 18:59** — la clase de esa noche abre con los evaluadores en cancha. El Foro de grupos del campus está abierto para armar equipos y coordinar.